

Post-stratification

сгенерировать rand-числ, а затем выбрать группу

$$(2) \hat{Y}_{\text{post}} = \sum_{k=1}^K p_k \bar{Y}_k, \quad \bar{Y}_k = \frac{1}{n_k} \sum_{j=1}^{n_k} Y_{kj}$$

Но $n_k \neq p_k \cdot N$ $n < N$ N — совокупность
 размер k -той группы в выборке ← размер выборки

total variance law n_k — размер k -той группы в выборке n_k — размер k -той группы в ген. совокупности n_k — размер k -той группы в ген. совокупности

$$\begin{aligned} \text{Var}(\hat{Y}_{\text{post}}) &= E\left(\text{Var}(\hat{Y}_{\text{post}} | n_1, \dots, n_K)\right) + \text{Var}\left(E(\hat{Y}_{\text{post}} | n_1, \dots, n_K)\right) = \\ &= E\left(\sum_{k=1}^K p_k^2 \text{Var}(\bar{Y}_k | n_k)\right) + \text{Var}\left(\sum_{k=1}^K p_k \mu_k\right) = E\left(\sum_{k=1}^K p_k^2 \frac{1}{n_k} \sigma_k^2\right) + \underbrace{\text{Var}(\mu)}_{=0} = \\ &= \sum_{k=1}^K p_k^2 \sigma_k^2 E\left(\frac{1}{n_k}\right). \end{aligned}$$

n_k — сл. вел., т.к. генер. сл. вел. выборки
 (*) \Rightarrow комбинации из строк k , которые не могут быть в выборке, следовательно

$$E\left(\frac{1}{n_k}\right) = ?$$

математ

$$\text{густ.} = n \cdot p_k (1 - p_k)$$

n_k - сл. величина Бернулли,
т.е. выборка размера n ,

$$\text{мат.от} = n \cdot p_k$$

p_k - вер-ть успехов

$$E(n_k) = n \cdot p_k$$

Расклад. в ряд Тейлора вокруг $\frac{1}{n \cdot p_k}$

$$\begin{aligned} E\left(\frac{1}{n_k}\right) &= E\left(\frac{1}{n \cdot p_k} + \frac{-1}{n^2 \cdot p_k^2} (n_k - n \cdot p_k) + \frac{1}{n^3 \cdot p_k^3} (n_k - n \cdot p_k)^2 + O\left(\frac{1}{n^2}\right)\right) = \\ &= \frac{1}{n \cdot p_k} + \frac{1}{n^3 \cdot p_k^3} E\left((n_k - n \cdot p_k)^2\right) + O\left(\frac{1}{n^2}\right) = \end{aligned}$$

$\text{Var}(n_k)$

$E(n_k)$

потому что

$$E\left(-\frac{n_k}{n^2 \cdot p_k^2} + \frac{n \cdot p_k}{n^2 \cdot p_k^2}\right) = -\frac{1}{n \cdot p_k} + \frac{1}{n \cdot p_k} = 0$$

подставляем

$$\text{Var}(\hat{Y}_{\text{post}}) = \sum_{k=1}^K p_k^2 \sigma_k^2 \left(\frac{1}{np_k} + \frac{1-p_k}{n^2 p_k^2} + o\left(\frac{1}{n^2}\right) \right) =$$

$$= \underbrace{\frac{1}{n} \sum_{k=1}^K p_k \sigma_k^2}_{\text{Var}(\hat{Y}_{\text{pre-stat}})} + \underbrace{\frac{1}{n^2} \sum_{k=1}^K (1-p_k) \sigma_k^2}_A + o\left(\frac{1}{n^2}\right)$$

$\text{Var}(\hat{Y}_{\text{pre-stat}})$

↓ сравнить

$$\text{Var}(\bar{Y}) = \frac{1}{n} \sum_{k=1}^K p_k \sigma_k^2 + \frac{1}{n} \underbrace{\sum_{k=1}^K p_k (\mu_k - \mu)^2}_{\text{конечное число}}$$

$$\Rightarrow \text{Var}(\hat{Y}_{\text{pre}}) \leq \text{Var}(\hat{Y}_{\text{post}}) \leq \text{Var}(\bar{Y})$$

\Rightarrow вывод: лучше суммировать заранее о результате экспериментов

т.к. все μ_k, p_k, K, n - конечные числа, то $\exists n_0$ достаточно большое, чтобы $A \leq B$
 $\frac{1}{n^2}$ убав. быстрее, чем n при $n \rightarrow \infty$

↓
 $\text{post-st} \downarrow$ значит по сравнению со случаем $n \rightarrow \infty$